Markus Gruber, M.Sc.

AI & Automation Engineer – M&A Automation

Python · *LLM APIs · Financial Data Pipelines · Agent Workflows · RAG*

3100 St. Pölten, Austria · +43 650 5871145 · Markus.Gruber4@gmx.net · LinkedIn · GitHub

Berufliches Profil



Analytischer Senior Machine Learning Engineer & Data Scientist mit einem M.Sc. in Scientific Computing und fundiertem mathematischen Hintergrund. Über 9 Jahre Industrieerfahrung in der Bereitstellung produktionsreifer KI-Pipelines und Datenarchitekturen.

Verbindet mathematisches Algorithmentuning, GPU-Edge-Beschleunigung (CUDA) und cloudnative RAG-Infrastrukturen (Vektordatenbanken, PyTorch). Hochgradig effektiv bei der Überführung komplexer ML-Modelle in performante Produktionssysteme.

Technisches Profil

TECHNISCHE GRUNDLAGEN & KI / DATENDOMÄNEN

KI & RAG-Infrastruktur	Data Engineering & Analytics	Hardwarebeschleunigung
RAG-Pipelines & Vektordatenbanken	PySpark, DuckDB, PostgreSQL	CUDA GPU Edge Beschleunigung
PyTorch, TensorFlow, Keras, ONNX	Scientific Computing (M.Sc. Uni Wien)	Eingebettete Vision Pipelines
LLM Orchestrierung (LangChain, LangGraph)	Apache Superset & Datenpipelines	Latenzarme Inferenzmaschinen

TECHNISCHE SPEZIALISIERUNG – ML & DATENSYSTEME

- **Produktionsreife KI-Infrastruktur:** Konzeption skalierbarer RAG-Architekturen, Integration von Vektordatenbanken und hochperformanten LLM-Inferenz-Backends.
- **Hardwarebeschleunigung & Edge ML:** Optimierung von Deep-Learning-Modellen (ONNX, PyTorch) mittels CUDA für latenzarme Ausführung auf GPU-Edge-Hardware.
- **Mathematische & Daten-Pipelines:** Anwendung numerischer Algorithmen, verteilter Datenverarbeitung (PySpark, DuckDB) und automatisierter Verifizierung in Daten-Workflows.

Berufserfahrung

Mindbreeze GmbH – Software / Quality Engineer (C++/Python) 09/2022 – 07/2026

C++, Python, REST APIs, Linux, Docker, Azure DevOps, Telemetrie & Performance-Profiling | Team: 6 Ingenieure

- Optimierung von Enterprise-Suchmaschinen-Indexdatenpipelines für verteilte Datenverarbeitung und großflächige Dokumentenverarbeitung.
- Entwicklung von Python-Automatisierungsframeworks zur Messung von End-to-End-Datendurchsatz und Systemantwortzeiten.
- Behebung von Speicherdegradierungen in Datenpipelines und Performance-Engpässen während hochvolumiger Produktions-Releases.

EYYES – Software Engineer (C++/Python) 04/2017 – 12/2020

C++, Python, Echtzeit-Ausführungspipelines, CUDA, Embedded GPU Edge | Team: 8 Ingenieure

- Entwicklung von Computer Vision- und Deep Learning-Pipelines (Keras, ONNX) für industrielle Kamera-Systeme zur Sicherstellung kontinuierlicher Echtzeit-Leistung auf Edge-Geräten.
- Entwicklung latenzarmer C++- und CUDA-Ausführungsroutinen für die Echtzeit-Videostreambearbeitung auf eingebetteten GPU-Edge-Geräten.
- Optimierung der Erkennungsgenauigkeit durch präzises Algorithmentuning und automatisierte Benchmarking-Suiten.

logi.cals – Embedded Software Engineer (C/C++) 02/2021 – 01/2022
C, C++, Embedded Systems, Deterministische Ausführung | Team: 6 Ingenieure

- Entwicklung deterministischer C/C++-Laufzeitsysteme und automatisierter Verifizierungstestsuiten für komplexe Hardwareumgebungen.

Untis GmbH – Software Engineer (C++) 02/2022 – 06/2022
C++, System-Refactoring, Performance-Profiling | Team: 10 Ingenieure

- Refactoring von Kernmodulen zur Optimierung der Speicherallokation und der algorithmischen Effizienz.

Ausgewählte Softwareprojekte

- **Azure AI Document Analyzer & RAG Infra:** RAG-Processing-Backend auf Azure unter Verwendung von Vektordatenbanken zur Analyse unstrukturierter Dokumente (GitHub).
  Tech: Python, RAG, Vektordatenbanken, LangChain, REST APIs
- **AWS Cloud Deep Learning Pipeline:** MLOps-Pipeline mit automatisierter Datenerfassung, PyTorch-Training und Cloud-Inferenz (GitHub).
  Tech: AWS, Python, PyTorch, MLOps, Docker
- **PySpark Analytics Pipeline:** End-to-End-Datenverarbeitungspipeline integriert mit DuckDB und Apache Superset Dashboards (GitHub).
  Tech: PySpark, DuckDB, PostgreSQL, Apache Superset

Technische Kenntnisse

ML, KI & Daten: PyTorch, TensorFlow, Keras, ONNX, RAG-Infrastruktur, Vektordatenbanken, LangChain, LangGraph, PySpark, DuckDB, PostgreSQL, Apache Superset.
Kernsysteme & GPU: Modernes C++, Python, CUDA, OpenCL, OpenMP, MPI, Linux, Docker, REST APIs.
Cloud & DevOps: Amazon AWS, Microsoft Azure, GitLab CI/CD, Git, Telemetrie, Cursor, GitHub Copilot.

Ausbildung

M.Sc. Scientific Computing – Universität Wien 10/2013 – 06/2017
Masterarbeit: Silent Data Corruption in FT-GMRES (Link, Betreuer: Prof. Dr. W. Gansterer).

B.Sc. Industrial Simulation – FH St. Pölten 09/2010 – 06/2013
Bachelorarbeit: Simulation von Nanokomposit-Materialien (Link, Betreuer: Prof. Dr. T. Schrefl).

Engineering Approach & Mindset

- **Systematic Problem Solving:** First-principles analytical approach to systematic debugging and stability optimization.
- **Quality & Efficiency Focus:** Pragmatic engineering mindset balancing rapid deployment with long-term maintainability and high performance.
- **Cross-Functional Integration:** Acts as the technical glue bridging development, QA, and architecture.

Sprachen & Arbeitsstatus

Deutsch: Muttersprache (C2) · **Englisch:** Verhandlungssicher (C1/C2) · **Arbeitserlaubnis:** EU-Bürger / Österreich