Markus Gruber, M.Sc.

Senior Machine Learning Engineer
Data Scientist

AI Infrastructure · *RAG Pipelines* · *Scientific Computing Specialist*

3100 St. Pölten, Österreich · +43 650 5871145 · Markus.Gruber4@gmx.net · LinkedIn · GitHub

Kurzprofil



Senior Machine Learning Engineer & Data Scientist mit über 9 Jahren Erfahrung in der Entwicklung von Deep-Learning-Pipelines, KI-Infrastrukturen und datengetriebenen Systemen. M.Sc. in Scientific Computing mit ausgeprägtem mathematischen Schwerpunkt. Verbindet fundiertes numerisches Verständnis mit praxisnaher Softwareentwicklung. Spezialisiert auf GPU-Beschleunigung (CUDA/ONNX), moderne RAG-Architekturen und skalierbare Daten-Pipelines für produktive Enterprise-Umgebungen.

Arbeitsweise & Prinzipien

- **Strukturierte Problemlösung:** Analytischer Ansatz auf Basis grundlegender Prinzipien zur systematischen Fehlersuche und Optimierung der Systemstabilität.
- **Qualitäts- und Effizienzorientierung:** Pragmatische Engineering-Mentalität, die schnelle Umsetzung mit langfristiger Wartbarkeit und hoher Leistungsfähigkeit in Einklang bringt.
- **Funktionsübergreifende Zusammenarbeit:** Übernimmt eine verbindende technische Rolle zwischen Entwicklung, Qualitätssicherung (QA) und Architektur.

Kernkompetenzen

TECHNISCHES FUNDAMENT & KI / DATA DOMAINS

Machine Learning & AI	Data Engineering & RDBMS	Systems & Acceleration
PyTorch, TensorFlow, Keras, ONNX	PySpark, DuckDB, PostgreSQL	Modern C++, Python,
RAG Infra, LangChain, LangGraph	SQLAlchemy, Apache Superset	CUDA/OpenCL
Computer Vision & Inference	Distributed Data Processing	Docker, AWS & Azure Cloud
		CI/CD & Performance Tuning

KERN-SPEZIALISIERUNG – ARTIFICIAL INTELLIGENCE & DATA SCIENCE

- **AI Infrastructure & RAG Architecture:** Konzeption und Bereitstellung cloud-nativer RAG-Backends, Vektordatenbank-Integrationen und skalierbarer LLM-Pipelines.
- **Deep Learning & Hardware Acceleration:** Optimierung von Computer-Vision- und Inferenz-Pipelines mittels CUDA, ONNX und Keras für Embedded- und Edge-Systeme.
- **Data Engineering & Analytics:** Aufbau skalierbarer Daten-Pipelines mit PySpark, DuckDB und PostgreSQL zur effizienten Analyse und Verarbeitung großer Datenmengen.

Berufserfahrung

Mindbreeze GmbH – Software / Quality Engineer (C++/Python) 09/2022 – 07/2026

C++, Python, REST APIs, Linux, Docker, DevOps, Telemetry & Performance Profiling · *Team: 6 Engineers*

- Entwicklung von Python/Bash-Automatisierungsframeworks zur Verkürzung der Release-Performance-Tests von 10 auf 3 Arbeitstage.
- Optimierung leistungskritischer Backend-Komponenten für Unternehmensarchitekturen zur verteilten Datenverarbeitung.
- Refactoring von Suchmaschinen-Kernmodulen und Optimierung von Index-Datenpipelines zur Steigerung der Suchleistung.

- Zentraler technischer Ansprechpartner in Release-Phasen zur Behebung von Systemengpässen und Performance-Einbußen.

Untis GmbH – Software Engineer (C++) 02/2022 – 06/2022
C++, System Refactoring, Performance Profiling, Core Desktop Modules · Team: 10 Engineers

- Refactoring von Legacy-C++/MFC-Kernmodulen in Visual Studio zum Abbau technischer Schulden, Optimierung der Speicherallokation und Stabilisierung des Systems.

logi.cals – Embedded Software Engineer (C/C++) 02/2021 – 01/2022
C, C++, Embedded Systems, Safety-Critical Architectures, Deterministic Execution · Team: 6 Engineers

- Entwicklung deterministischer C/C++-Laufzeitsysteme (Software-SPS) und automatisierter Test-Suiten für sicherheitskritische Zertifizierungen über diverse Hardware-Plattformen hinweg.

EYYES – Software Engineer (C++/Python) 04/2017 – 12/2020
C++, Python, Real-Time Execution Pipelines, CUDA, Embedded GPU Edge · Team: 8 Engineers

- Entwicklung und Implementierung KI-gestützter Bildverarbeitungspipelines (Keras, ONNX) für industrielle Echtzeit-Kamerasysteme und Edge-Computing-Plattformen.
- Entwicklung latenzarmer C++/CUDA-Routinen zur performanten Echtzeit-Videoverarbeitung auf Embedded-GPUs.
- Implementierung hardwarenaher C++-Komponenten zur Steuerung von Kamerasensoren, Schrittmotoren und SerDes-Schnittstellen.
- Entwicklung, Training und Optimierung mehrerer TensorFlow-basierter Klassifikatoren zur Erreichung einer Klassifikationsgenauigkeit von 99,99 %.

Ausgewählte Projekte

- **Azure AI Document Analyzer & RAG Infra:** Dokumentenindexierungs- und RAG-Retrieval-Backend mit hohem Durchsatz auf Azure unter Einsatz von Vektordatenbanken (GitHub).
  Tech: Python, RAG, Vector DBs, Azure, Microservices
- **AWS Cloud Deep Learning Pipeline:** End-to-End Cloud-Pipeline zur automatisierten Datenaufnahme und High-Throughput-PyTorch-Modellinferenz (GitHub).
  Tech: AWS, Python, PyTorch, MLOps, REST APIs
- **Magnum C++ Game of Life:** Hochperformante C++-Simulation mit Fokus auf Low-Level-Speicherlayout und Cache-Lokalität (GitHub).
  Tech: Modern C++, Memory Layout, Performance Optimization, Grid Logic

Technische Kenntnisse

ML, AI & Data Engineering: PyTorch, TensorFlow, Keras, ONNX, RAG Infrastructure, LangChain, LangGraph, PySpark, DuckDB, PostgreSQL, SQLAlchemy, Apache Superset.
Languages & Core: Modern C++, C, Python, SQL, Java, Bash, Parallel Algorithms, Scientific Computing.
Cloud, Systems & Infra: Amazon AWS (S3, RDS, EC2), Microsoft Azure, Linux (Ubuntu/Debian), Windows, Docker, Microservices, REST APIs.
DevOps, QA & Tooling: GitLab CI/CD, GitHub Actions, DevOps, Git, Telemetry, Cursor, GitHub Copilot, CUDA, OpenCL, OpenMP, MPI.

Ausbildung & Studium

M.Sc. Scientific Computing – Universität Wien 10/2013 – 06/2017
Thesis: Silent Data Corruption in FT-GMRES (Link, Betreuer: Prof. Dr. W. Gansterer).

B.Sc. Industrial Simulation – FH St. Pölten 09/2010 – 06/2013
Thesis: Simulation of Nanocomposite Materials (Link, Betreuer: Prof. Dr. T. Schrefl).

Sprachen Rahmenbedingungen

German: Muttersprache (C2) · **English:** Verhandlungssicher (C1/C2) · **Arbeitserlaubnis:** EU-Bürger / Österreich